

Predicción de GRD obstétricos mediante aprendizaje profundo: LSTM y GRU

MELISSA GARDUÑO RUIZ, ALEXANDRA CUEVAS GUERRERO, RODRIGO ORTEGA DÍAZ y FRANCISCO CORREA ORTIZ

MSI608, Tópicos avanzados en ciencia de datos

Magíster en Ingeniería Informática

• **RESUMEN** La asignación precisa de los Grupos Relacionados por el Diagnóstico (GRD) constituye un desafío para la administración hospitalaria y la auditoría clínica. Este estudio propone un enfoque de aprendizaje profundo que compara redes recurrentes LSTM y GRU para predecir el GRD a partir de códigos de diagnóstico y procedimiento. Se utiliza una cohorte de 1.220 egresos de cesárea, seleccionada de 14.561 registros, con tres categorías de distinta complejidad. Para abordar el desbalance se evalúa una configuración con SMOTE aplicada al entrenamiento y secuencias estandarizadas de 65 posiciones. LSTM obtiene exactitud de 0,889 y F1 macro de 0,865, frente a 0,885 y 0,854 de GRU. El análisis de confusión identifica mayor dificultad en la categoría con complicaciones no mayores. Se emplean explicaciones SHAP globales y locales para examinar la influencia de diagnósticos secundarios y las contribuciones a una predicción individual. Los resultados favorecen preliminarmente a LSTM, aunque requieren validar la plausibilidad del sobremuestreo y conciliar las métricas experimentales. El trabajo futuro considera arquitecturas multimodales, mecanismos de atención y validación externa para ampliar la utilidad del modelo.

• **PALABRAS CLAVE** Aprendizaje profundo, GRD, GRU, LSTM, registros médicos electrónicos, SHAP, SMOTE.

I. INTRODUCCIÓN

La automatización de la auditoría clínica y los procesos automatizados de facturación médica es esencial para la eficiencia institucional. El sistema de Grupos Relacionados por el Diagnóstico (GRD) agrupa egresos con perfiles clínicos y consumo de recursos similares. La asignación depende de la codificación de diagnósticos y procedimientos, realizada por profesionales que revisan registros médicos electrónicos; errores y retrasos pueden afectar la gestión hospitalaria [1], [2].

El proyecto aborda la clasificación de tres GRD obstétricos relacionados con cesárea. Los diagnósticos y procedimientos se tratan como secuencias lógicas de registro para apoyar una clasificación precisa e interpretable. La tarea es multiclase, con una etiqueta por egreso. El alcance es retrospectivo: la disponibilidad de códigos al alta no demuestra capacidad de anticipar el GRD al ingreso.

I-A. OBJETIVO DEL ESTUDIO

Desarrollar y comparar modelos LSTM y GRU para predecir los GRD 146101, 146102 y 146103. Se busca analizar calidad y distribución de los datos, definir una representación de códigos clínicos, justificar las arquitecturas

y métricas, seleccionar un candidato y explicar sus errores mediante matrices de confusión y SHAP.

II. REVISIÓN BIBLIOGRÁFICA

La investigación en registros electrónicos ha explorado aprendizaje profundo para representar códigos clínicos dispersos. Islam *et al.* [1] desarrollaron DeepDRG con 81.486 pacientes y 128.105 episodios. Su GRU, orientada a 200 diagnósticos principales vinculados al proceso GRD, obtuvo AUC de 0,99, precisión de 0,832 y recall de 0,660. Estos resultados motivan estudiar redes recurrentes, sin asumir equivalencia entre ese objetivo y la presente clasificación obstétrica.

Liu *et al.* [2] procesaron notas clínicas para anticipar MS-DRG y APR-DRG, con AUC macro de 0,871 y 0,884 durante el primer día en UCI. Wang *et al.* [3] ajustaron DRG-LLaMA sobre 236.192 resúmenes de alta; su configuración de 7.000 millones de parámetros y 512 tokens alcanzó exactitud de 0,520 y F1 macro de 0,327. Las diferencias de población, entrada y número de categorías impiden interpretar estas métricas como un ranking directo frente al presente estudio.

III. ANÁLISIS DE DATOS

III-A. DESCRIPCIÓN DEL DATASET Y SELECCIÓN DE LA COHORTE

El conjunto de datos utilizado, `dataset_elpino.csv`, contiene inicialmente 14.561 registros de egresos. La unidad de análisis es el episodio hospitalario y no necesariamente un paciente único. Cada registro reúne códigos de diagnóstico y procedimiento, variables demográficas y la etiqueta GRD. Las posiciones clínicas comprenden hasta 35 diagnósticos y 30 procedimientos; Edad y Sexo se utilizan para caracterización, pero no como entradas de las redes.

Para enfocar el alcance predictivo se seleccionan tres categorías de cesárea: 146101, sin modificador de complicación; 146102, con complicación o comorbilidad (CC); y 146103, con complicación o comorbilidad mayor (MCC). La cohorte resultante contiene 1.220 egresos, el 8,38 % del conjunto inicial. La selección es clínica y no corresponde a los tres GRD globalmente más frecuentes. Compartir el procedimiento base concentra el problema en distinguir niveles de complejidad.

III-B. COMPLETITUD, CORRECTITUD Y VALORES EXTREMOS

La evaluación de calidad reveló valores nulos en Edad, imputados mediante la mediana para el análisis descriptivo. Esta imputación no interviene directamente en LSTM o GRU, porque la edad se excluye de sus entradas. La tasa de ausencia por campo queda pendiente de cuantificación. Una posición diagnóstica vacía puede significar que no se registró otro diagnóstico, por lo que debe distinguirse de un dato perdido o de un código desconocido.

Las tablas de contingencia muestran distribuciones diagnósticas distintas según el GRD objetivo, lo que sugiere señal discriminativa. Sin embargo, asociación estadística no equivale a correctitud clínica. La validación debe contrastar formatos y catálogos de códigos, duplicados, coherencia entre diagnósticos y procedimientos y versión del agrupador. La auditoría por identificador de paciente es necesaria para evitar que reingresos contaminen una partición de entrenamiento y prueba.

El histograma (Fig. 1) presenta concentraciones en edades tempranas y adultas y una cola superior prolongada. En el conjunto completo, edades próximas a cero pueden corresponder a hospitalizaciones pediátricas; en la cohorte obstétrica requieren revisar selección y unidades. Los extremos no se eliminan automáticamente: se distingue una observación infrecuente de un valor clínicamente imposible. No se dispone de una cuantificación de errores de edad ni de duplicados para afirmar que estos problemas están resueltos.

III-C. ESTADÍSTICAS DESCRIPTIVAS Y DESBALANCE DE CLASES

El análisis exploratorio evidencia desbalance: 813 egresos pertenecen a 146101, 244 a 146102 y 163 a 146103 (Tabla 1). La razón entre las clases extrema es $813/163 = 4,99$. Un clasificador que eligiera siempre 146101 acertaría el 66,6 % en la cohorte, sin recuperar las categorías con CC y MCC. Por ello, accuracy no constituye un criterio suficiente de selección.

Tabla 1. Composición de la cohorte de estudio.

GRD	Egresos	Proporción	Categoría
146101	813	66,6 %	Cesárea
146102	244	20,0 %	Cesárea con CC
146103	163	13,4 %	Cesárea con MCC
Total	1.220	100 %	Tres clases




Figura 2. Frecuencia de los tres GRD seleccionados. La categoría 146101 concentra aproximadamente dos tercios de los egresos.




Figura 1. Distribución de Edad en el conjunto hospitalario original. El histograma representa egresos generales y no exclusivamente la cohorte de cesáreas.

IV. METODOLOGÍA

IV-A. SECUENCIACIÓN Y SELECCIÓN DE CARACTERÍSTICAS

Las características de entrada se limitaron a códigos de diagnóstico y procedimiento. Se excluyeron las variables demográficas estáticas, Edad y Sexo, para aislar la eficacia del procesamiento secuencial. Se construyó un vocabulario unificado de 533 índices y se estandarizaron los registros a una longitud máxima de 65 posiciones mediante padding. Los 377 diagnósticos y 155 procedimientos suman 532 códigos; la diferencia es compatible con un índice reservado, cuyo tratamiento debe verificarse junto con los símbolos PAD y OOV.

La secuencia conserva el orden lógico de las columnas, no una cronología clínica demostrada. El proceso comprende seleccionar la cohorte, transformar los códigos, separar desarrollo y evaluación, aplicar balanceo al entrenamiento y ajustar las redes. El vocabulario y cualquier transformación aprendida deben estimarse sin observar la prueba. El enmascaramiento del padding evita interpretarlo como un evento clínico.

IV-B. BALANCEO DE DATOS CON SMOTE

Para mitigar el desbalance, se aplicó SMOTE exclusivamente sobre el entrenamiento [4]. Dado que las secuencias alimentan una capa de embedding, los resultados de la interpolación se redondearon a enteros. Este paso conserva el tipo de dato, pero no garantiza plausibilidad clínica: los índices son identificadores nominales y no distancias entre diagnósticos. Interpolarse dos índices puede producir un tercer código sin relación médica con ellos.

Por esta razón, el efecto de SMOTE se interpreta como exploratorio. La evaluación ampliada contrastará esta configuración con pesos de clase y sobremuestreo aleatorio de secuencias completas, además de una condición sin balanceo. Los tratamientos se aplicarán dentro del entrenamiento de cada partición, sin generar ejemplos sintéticos en validación o prueba.

IV-C. MÉTRICAS DE EVALUACIÓN

Se utilizan precisión, sensibilidad (recall), F1 macro y ROC-AUC bajo One-vs-Rest (OvR), junto con accuracy y matriz de confusión. Para la clase k :

$$P_k = \frac{TP_k}{TP_k + FP_k}, \quad R_k = \frac{TP_k}{TP_k + FN_k}. \quad (1)$$

El criterio principal es

$$F1_{\text{macro}} = \frac{1}{3} \sum_{k=1}^3 \frac{2P_k R_k}{P_k + R_k}. \quad (2)$$

F1 macro asigna igual importancia a cada GRD y equilibra precisión y recuperación. El recall por clase identifica subclasificaciones de CC y MCC, mientras la matriz revela su dirección. ROC-AUC evalúa discriminación probabilística, pero un área elevada no garantiza sensibilidad suficiente en

la decisión final. Accuracy resume aciertos globales y se interpreta junto con estas medidas.

V. ARQUITECTURAS CANDIDATAS Y EXPERIMENTOS

Se diseñaron dos modelos secuenciales con una representación de entrada común. Ambos reciben secuencias estandarizadas en una capa de embedding de dimensión 64, que proyecta los códigos a un espacio vectorial denso (Fig. 3).

Candidato 1: LSTM. Incorpora una capa de 32 unidades con memoria y compuertas para retener o descartar información de la secuencia [5]. Se elige para estudiar dependencias entre diagnósticos principales, secundarios y procedimientos.

Candidato 2: GRU. Utiliza 32 unidades con compuertas de actualización y reinicio [6]. Su estructura más compacta motiva evaluar eficiencia y capacidad de generalización, aunque no demuestra por sí sola menor sobreajuste o tiempo de entrenamiento.




Figura 3. Arquitecturas comparadas: representación común, capa recurrente LSTM o GRU y salida softmax para tres categorías.

Ambas redes finalizan en una capa densa con softmax y se entrenaron con Adam, entropía cruzada categórica y una configuración de 16 épocas con parada temprana. Esta última busca limitar el sobreajuste. La igualdad de unidades no implica igualdad de parámetros; la comparación computacional requiere registrar el tamaño real del modelo y el tiempo de ejecución. Semilla, tamaño de lote, tasa de aprendizaje y paciencia deben fijarse explícitamente para una evaluación reproducible.

VI. RESULTADOS Y SELECCIÓN DEL MODELO

VI-A. RESULTADOS COMPARATIVOS

La evaluación preliminar arrojó los resultados de la Tabla 2. LSTM supera a GRU en accuracy, precisión, recall y F1 macro. La diferencia de F1 macro es 0,011, equivalente a 1,1 puntos porcentuales; la diferencia de accuracy es de 0,4 puntos. Accuracy es una medida global y no un promedio macro.

Tabla 2. Comparación preliminar de las dos arquitecturas.

Métrica	LSTM + SMOTE	GRU + SMOTE
Accuracy	0,889	0,885
Precisión macro	0,881	0,861
Recall macro	0,858	0,849
F1 macro	0,865	0,854

VI-B. JUSTIFICACIÓN DE LA SELECCIÓN

Se selecciona LSTM como candidato principal del proyecto por su mayor F1 macro y su mejor recuperación promedio de las clases. Esta elección es preliminar: una diferencia puntual no acredita estabilidad entre semillas ni superioridad general. Tampoco demuestra que SMOTE sea la causa exclusiva de la recuperación minoritaria, pues falta una comparación controlada con otras estrategias de balanceo.

La evaluación por clase incluye 244 egresos, el 20 % de la cohorte, y deja 976 registros para desarrollo. Los soportes 162, 49 y 33 preservan aproximadamente las proporciones originales. La matriz de LSTM (Fig. 4) contiene 217 aciertos y 27 errores; permite identificar confusiones que las métricas agregadas no muestran.

GRD observado \ GRD predicho	146101	146102	146103
146101	149	11	2
146102	10	39	0
146103	3	1	29

Figura 4. Matriz de confusión multiclase de LSTM para 244 egresos. Filas: GRD observado; columnas: GRD predicho.

VI-C. DESEMPEÑO POR CLASE Y LÍNEA BASE

La Tabla 3 deriva las métricas de los conteos de la matriz. La categoría 146102 presenta la mayor dificultad: se recuperan 39 de 49 casos y diez se clasifican como 146101. En 146103 hay cuatro falsos negativos: tres pasan a 146101 y uno a 146102. La subclasificación de complejidad merece revisión clínica, incluso cuando accuracy es elevada.

Tabla 3. Métricas calculadas desde la matriz de LSTM.

GRD	Soporte	Precisión	Recall	F1
146101	162	0,920	0,920	0,920
146102	49	0,765	0,796	0,780
146103	33	0,935	0,879	0,906
Macro	—	0,873	0,865	0,869

Un control que predijera siempre 146101 obtendría accuracy de $162/244 = 0,664$ y F1 macro de 0,266. Frente a este control, la matriz de LSTM implica una mejora de 22,5 puntos porcentuales en exactitud. La recuperación de 146102 y 146103 muestra que el modelo no se limita a la clase mayoritaria, aunque persisten errores entre niveles próximos de complejidad.

VI-D. CURVAS ROC Y CONSISTENCIA EXPERIMENTAL

Las curvas ROC OvR de LSTM presentan AUC de 0,93, 0,92 y 0,99 para 146101, 146102 y 146103, respectivamente (Fig. 5). El promedio simple es aproximadamente 0,947. El menor F1 de 146102 confirma que la discriminación probabilística y la calidad de la etiqueta final son aspectos complementarios.




Figura 5. Curvas ROC One-vs-Rest de LSTM. Todas las AUC superan 0,90; la diagonal representa discriminación al azar.

El F1 macro de 0,869 calculado desde la matriz difiere del 0,865 de la comparación global; también cambian precisión y recall macro. La diferencia no se explica por redondeo a tres decimales. Se mantienen ambos resúmenes sin promediarlos, pendientes de verificar correspondencia entre partición, balanceo y predicciones antes de consolidar una estimación definitiva.

VII. ANÁLISIS DE DESEMPEÑO Y EXPLICABILIDAD

Se empleó SHAP (SHapley Additive exPlanations) para analizar la toma de decisiones del modelo LSTM seleccionado. Este marco asigna contribuciones a las características de una predicción [7]. La explicabilidad global permite examinar qué posiciones pesan más en conjunto, mientras la local muestra cómo se combinan contribuciones en un caso. Ambas perspectivas complementan las métricas, pero no sustituyen la auditoría clínica ni demuestran causalidad.

VII-A. EXPLICABILIDAD GLOBAL

El resumen global (Fig. 6) sitúa Diag03 y Diag04 por encima de Diag01 en impacto predictivo medio. Diag02 también concentra una contribución importante. El predominio de posiciones diagnósticas secundarias es compatible con la diferenciación entre complicaciones y comorbilidades: las tres clases comparten la cesárea como procedimiento base, por lo que la separación de complejidad requiere información adicional.




Figura 6. Importancia global de posiciones clínicas mediante la media del valor absoluto de SHAP. Diag03 y Diag04 concentran las mayores contribuciones.

La medida representada es $\text{mean}(|\phi_j|)$, donde ϕ_j es la contribución SHAP de la posición j . Resume magnitud, no dirección: una característica importante puede aumentar o disminuir una salida según el caso. El predominio de diagnósticos entre las posiciones mostradas no demuestra que los procedimientos carezcan de utilidad en otros grupos hospitalarios.

La interpretación es posicional, no cronológica. Diag03 representa una columna del registro y puede contener dis-

tintos diagnósticos en diferentes egresos. Para convertir el gráfico en una explicación clínica se requiere recuperar el código asociado a cada índice y estudiar su contribución por clase. El orden de importancia no debe presentarse como una jerarquía causal de enfermedades.

VII-B. EXPLICABILIDAD LOCAL

Los gráficos de cascada permiten examinar cómo el modelo pondera señales con efectos opuestos. En el ejemplo de la Fig. 7, Diag01 tiene una contribución positiva aproximada de 0,25 y Diag02 y Diag03 contribuyen negativamente, con valores de alrededor de $-0,17$ y $-0,06$. El gráfico sitúa la referencia en $E[f(X)] = 0,6$ y la salida en $f(x) = 0,611$; las contribuciones mostradas están redondeadas.




Figura 7. Explicación local SHAP de una salida de LSTM. Los colores distinguen contribuciones positivas y negativas respecto del valor de referencia.

La presencia de contribuciones contrapuestas explica por qué no basta con encontrar un diagnóstico asociado a mayor complejidad: el modelo integra múltiples posiciones antes de emitir su salida. Los valores 120, 301 y 473 corresponden a índices del vocabulario en este ejemplo y no deben interpretarse como magnitudes clínicas. Su traducción a códigos permitiría verificar si la ponderación concuerda con la información del episodio.

VII-C. ANÁLISIS DE FALSOS NEGATIVOS Y APLICACIÓN CLÍNICA

En casos mal clasificados, una revisión local puede identificar si contribuciones negativas compensan la señal de complicaciones relevantes. Sin embargo, el ejemplo de cascada no incluye la etiqueta real ni identifica explícitamente la clase explicada; por sí solo no permite afirmar que sea un falso negativo. Para ese análisis deben vincularse la explicación, la predicción y el GRD verdadero del mismo egreso.

La revisión prioritaria corresponde a los casos 146102 o 146103 clasificados como 146101. El procedimiento propuesto consiste en identificar esos errores, recuperar los códigos que ocupan las posiciones relevantes y contrastarlos con especialistas. Así se distingue un fallo del modelo de un posible problema de registro o codificación. Las explicaciones sirven como apoyo a la revisión, no como evidencia suficiente para modificar automáticamente un GRD.

VIII. CONCLUSIONES Y TRABAJO FUTURO

VIII-A. CONCLUSIONES DEL ESTUDIO

La combinación de una representación secuencial de códigos clínicos y redes recurrentes permite estudiar la clasificación de GRD obstétricos con diferentes niveles de complejidad. En la cohorte de 1.220 egresos, LSTM obtiene F1 macro de 0,865 frente a 0,854 de GRU en la comparación preliminar, por lo que se selecciona como candidato principal. La exactitud de 0,889 supera la de 0,885 de GRU, aunque esta diferencia debe evaluarse con incertidumbre y repeticiones.

La matriz de confusión muestra recuperación de las tres categorías y mayor dificultad en 146102. Este resultado confirma la importancia de evaluar sensibilidad y F1 por clase, además de accuracy. El análisis SHAP global destaca diagnósticos secundarios, mientras las explicaciones locales muestran contribuciones opuestas en una misma predicción. Su combinación permite orientar la revisión de errores y formular hipótesis clínicas que deben ser verificadas por especialistas.

SMOTE forma parte de la configuración exploratoria, pero no puede considerarse una solución definitiva al desbalance. El redondeo de índices interpolados no garantiza secuencias clínicamente plausibles. También debe resolverse la diferencia entre las métricas agregadas y las derivadas de la matriz. Estas limitaciones no eliminan la señal predictiva observada, pero impiden atribuir una mejora causal al sobremuestreo o afirmar superioridad universal de LSTM.

VIII-B. PROPUESTAS DE DESARROLLO

Arquitectura multimodal. Se propone fusionar la salida LSTM con una rama densa para Edad, Sexo y otras características estáticas. Esto permitiría evaluar el aporte incremental de variables excluidas de la representación secuencial, con imputación ajustada solo en entrenamiento y análisis del desempeño por subgrupos.

Mecanismos de atención. Una ampliación de la muestra permitiría explorar modelos que ponderen directamente códigos relevantes y, cuando existan entradas textuales adecuadas, arquitecturas basadas en Transformers. Los antecedentes sobre notas clínicas y DRG-LLaMA [2], [3] motivan esa línea, pero no demuestran que un modelo mayor supere a las redes actuales en esta cohorte pequeña.

Balanceo y validación. Se compararán pesos de clase, sobremuestreo de secuencias completas y entrenamiento sin balanceo. La evaluación utilizará particiones comunes para ambas redes, varias semillas y validación cruzada estratificada dentro de desarrollo. Si hay reingresos, la separación debe agrupar episodios del mismo paciente. La prueba temporal o en otra institución permitirá valorar generalización ante cambios en población y codificación.

VIII-C. REPRODUCIBILIDAD Y ALCANCE OPERATIVO

La siguiente etapa debe fijar versión del agrupador, diccionario de códigos, semilla, lote, tasa de aprendizaje y criterio de parada temprana. Se conservarán probabilidades,

etiquetas e identificadores de partición para conciliar métricas y estimar intervalos de confianza. También se registrarán tiempos y memoria para comprobar si GRU ofrece una ventaja computacional real, sin inferirla únicamente de su estructura.

El sistema se concibe como apoyo a la auditoría de egresos, no como sustituto del agrupador oficial o del juicio del codificador. Su implementación requiere revisión humana, protección de datos clínicos y seguimiento de errores, especialmente de subclasificación de CC y MCC. Un AUC alto o una explicación plausible no bastan para justificar decisiones automáticas sobre codificación o financiamiento.

Referencias

- [1] M. M. Islam, G.-H. Li, T. N. Poly y Y.-C. Li, "DeepDRG: Performance of Artificial Intelligence Model for Real-Time Prediction of Diagnosis-Related Groups," *Healthcare*, vol. 9, n.º 12, art. 1632, 2021, doi: 10.3390/healthcare9121632.
- [2] J. Liu, D. Capurro, A. Nguyen y K. Verspoor, "Early prediction of diagnostic-related groups and estimation of hospital cost by processing clinical notes," *npj Digital Medicine*, vol. 4, art. 103, 2021, doi: 10.1038/s41746-021-00474-9.
- [3] H. Wang, C. Gao, C. Dantona, B. Hull y J. Sun, "DRG-LLaMA: tuning LLaMA model to predict diagnosis-related group for hospitalized patients," *npj Digital Medicine*, vol. 7, art. 16, 2024, doi: 10.1038/s41746-023-00989-3.
- [4] N. V. Chawla, K. W. Bowyer, L. O. Hall y W. P. Kegelmeyer, "SMOTE: Synthetic minority over-sampling technique," *Journal of Artificial Intelligence Research*, vol. 16, pp. 321–357, 2002, doi: 10.1613/jair.953.
- [5] S. Hochreiter y J. Schmidhuber, "Long short-term memory," *Neural Computation*, vol. 9, n.º 8, pp. 1735–1780, 1997, doi: 10.1162/neco.1997.9.8.1735.
- [6] K. Cho *et al.*, "Learning phrase representations using RNN encoder-decoder for statistical machine translation," en *Proc. EMNLP*, pp. 1724–1734, 2014, doi: 10.3115/v1/D14-1179.
- [7] S. M. Lundberg y S.-I. Lee, "A unified approach to interpreting model predictions," en *Advances in Neural Information Processing Systems*, vol. 30, pp. 4765–4774, 2017.

...